

Sea un modelo de Markov de conjunto de estados $Q = \{1, 2, F\}$ y conjunto de símbolos $\Sigma = \{a, b\}$. Se pide:

a) Sean el vector de probabilidades iniciales (π), matriz de transición entre estados (A) y matriz de generación de símbolos (B):

π	1	2
	0.6	0.4

A	1	2	F
1	0.6	0.3	0.1
2	0.3	0.4	0.3

B	a	b
1	0.3	0.7
2	0.8	0.2

Realiza una traza del algoritmo de Viterbi para la cadena $y = aab$ obteniendo la mejor secuencia de estados.

b) Sean las tres cadenas de símbolos: $y_1 = bbaa$, $y_2 = abab$ y $y_3 = aabbb$. Al aplicar el algoritmo de Viterbi con un cierto modelo de Markov M , se obtienen, respectivamente, las siguientes secuencias óptimas de estados: 1122F, 2121F y 22111F. A partir de dichas cadenas y sus respectivas secuencias óptimas de estados, re-estima las probabilidades iniciales (π), de transición (A) y de emisión (B) de M (del mismo modo que se hace en una iteración del algoritmo de re-estimación de Viterbi).

a) Traza del algoritmo de Viterbi para la cadena $y = aab$:

V	a	a	b	
1	$0.6 \cdot 0.3 = 0.18$	$0.18 \cdot 0.6 \cdot 0.3 = 0.0324$ $0.32 \cdot 0.3 \cdot 0.3 = 0.0288$ $0.0324 > 0.0288$ (de 1)	$0.0324 \cdot 0.6 \cdot 0.7 = 0.0136$ $0.1024 \cdot 0.3 \cdot 0.7 = 0.0215$ $0.0136 < 0.0215$ (de 2)	
2	$0.4 \cdot 0.8 = 0.32$	$0.18 \cdot 0.3 \cdot 0.8 = 0.0432$ $0.32 \cdot 0.4 \cdot 0.8 = 0.1024$ $0.0432 < 0.1024$ (de 2)	$0.0324 \cdot 0.3 \cdot 0.2 = 0.0019$ $0.1024 \cdot 0.4 \cdot 0.2 = 0.0082$ $0.0019 < 0.0082$ (de 2)	
F	—	—	—	$0.0215 \cdot 0.1 = 0.0022$ $0.0082 \cdot 0.3 = 0.0025$ $0.0022 < 0.0025$ (de 2)

La secuencia óptima de estados es: 222F

b) La estimación de π , A y B para las cadenas de entrenamiento $y_1 = bbaa$, $y_2 = abab$ y $y_3 = aabbb$ es

π : El estado 1 se ha utilizado una vez como estado inicial y el estado 2 dos veces.

A : ■ La transición 1-1 3 veces, la 1-2 2 veces, la 1-F dos veces

■ La transición 2-1 3 veces, la 2-2 2 veces, la 2-F una vez

B : ■ El símbolo a se ha emitido 0 vez en el estado 1 y 6 veces en el estado 2

■ El símbolo b se ha emitido 7 veces del estado 1 y 0 veces del estado 2

Normalizando

	1	2
π	$\frac{1}{3}$	$\frac{2}{3}$

A	1	2	F
1	$\frac{3}{7}$	$\frac{2}{7}$	$\frac{2}{7}$
2	$\frac{1}{2}$	$\frac{1}{3}$	$\frac{1}{6}$

B	a	b
1	0.0	1.0
2	1.0	0.0

Sea un problema de clasificación en C clases para objetos representados mediante una característica de tipo contador, $x \in \{0, 1, 2, \dots\}$. Para toda clase c , suponemos dadas:

- Su probabilidad a priori, $P(c)$.
- Su función de (masa de) probabilidad condicional, $P(x | c)$, la cual es $\text{Poisson}(\lambda_c)$ con λ_c conocida.

Se pide:

- (0.5 puntos) Sea el caso particular: $C = 2$, $P(c = 1) = P(c = 2) = \frac{1}{2}$, $\lambda_1 = 1$, $\lambda_2 = 2$ y $x = 2$. Determina la probabilidad incondicional de ocurrencia de $x = 2$, $P(x = 2)$.
- (0.5 puntos) En el caso particular anterior, halla la probabilidad a posteriori $P(c = 2 | x = 2)$, así como la probabilidad de error si $x = 2$ se clasifica en la clase $c = 2$.
- (0.5 puntos) Más generalmente, para cualquier número de clases C y cualesquiera probabilidades a priori, considera el caso en el que, dado un cierto $\bar{\lambda} \in \mathbb{R}^+$, $\lambda_c = \bar{\lambda}$ para todo c . En tal caso, existe una clase que no depende de x , c^* , en la que se puede clasificar todo x con mínima probabilidad de error. Determinala.
- (0.5 puntos) En el caso general, prueba que el clasificador de Bayes para este problema puede expresarse como un clasificador basado en funciones discriminantes lineales como sigue (ln indica logaritmo natural):

$$c^*(x) = \arg \max_c g_c(x) \quad \text{con} \quad g_c(x) = w_c x + w_{c0}, \quad w_c = \ln \lambda_c \quad \text{y} \quad w_{c0} = \ln p(c) - \lambda_c$$

Solución:

- $P(x = 2 | c = 1) = \frac{1}{2e} = 0.1839$ $P(x = 2 | c = 2) = \frac{2}{e^2} = 0.2707$.
 $P(x = 2) = 0.5 \cdot 0.1839 + 0.5 \cdot 0.2707 = 0.2273$.
- $P(c = 2 | x = 2) = \frac{P(c=2) \cdot P(x=2|c=2)}{P(x=2)} = \frac{0.5 \cdot 0.2707}{0.2273} = 0.5955$.
 $P(c \neq 2 | x = 2) = 1 - P(c = 2 | x = 2) = 0.4045$.
- $c^*(x) = \arg \max_c P(c) P(x | c) = \arg \max_c P(c) \text{Poisson}(\lambda) = \arg \max_c P(c) \rightarrow c^* = \arg \max_c P(c)$.
-

$$\begin{aligned} c^*(x) &= \arg \max_c \ln P(c) + \ln P(x | c) \\ &= \arg \max_c \ln P(c) - \lambda_c + x \ln \lambda_c - \ln x! \\ &= \arg \max_c x \ln \lambda_c + (\ln P(c) - \lambda_c) \end{aligned}$$

Sea M un modelo de Markov de conjunto de estados $Q = \{1, 2, F\}$; alfabeto $\Sigma = \{a, b, c\}$; probabilidades iniciales $\pi_1 = \frac{1}{2}$, $\pi_2 = \frac{1}{2}$; y probabilidades de transición entre estados y de emisión de símbolos:

B	a	b	c
1	$\frac{2}{3}$	$\frac{1}{3}$	$\frac{1}{3}$
2	$\frac{2}{3}$	$\frac{1}{3}$	$\frac{1}{3}$

A	1	2	F
1	$\frac{1}{3}$	$\frac{2}{3}$	$\frac{1}{3}$
2	$\frac{2}{3}$	$\frac{1}{3}$	$\frac{1}{3}$

Sea $x = "ac"$. Se pide:

- (0, 75 puntos) Haz una traza del algoritmo *Forward* para hallar la probabilidad $P_M(x)$ de que M genere x .
- (0, 75 puntos) Realiza una traza del algoritmo de *Viterbi* para obtener la secuencia de estados más probable, $\tilde{q}_M(x)$, con la que M genera x .
- (0, 50 puntos) Con base en los resultados obtenidos en los apartados anteriores, podemos afirmar que M genera x con probabilidad $P_M(x)$, siguiendo la secuencia de estados $\tilde{q}_M(x)$. ¿Certo o falso? Razona brevemente la respuesta.
- (1 punto) A partir de las cadenas de entrenamiento x y " cb ", y sabiendo que $\tilde{q}_M(cb) = "21F"$, reestima a los parámetros de M mediante el algoritmo de reestimación por Viterbi (hasta convergencia).

1.

α_{qt}	a	c
1	$\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$	$\frac{1}{4} \cdot \frac{1}{4} \cdot \frac{1}{4} + \frac{1}{8} \cdot \frac{1}{2} \cdot \frac{1}{4} = \frac{1}{64} + \frac{1}{64} = \frac{2}{64}$
2	$\frac{1}{2} \cdot \frac{1}{4} = \frac{1}{8}$	$\frac{1}{4} \cdot \frac{1}{2} \cdot \frac{1}{2} + \frac{1}{8} \cdot \frac{1}{4} \cdot \frac{1}{2} = \frac{1}{16} + \frac{1}{64} = \frac{5}{64}$

$$P_M(x) = \frac{2}{64} \cdot \frac{1}{4} + \frac{5}{64} \cdot \frac{1}{4} = \frac{7}{256}$$

2.

V_{qt}	a	c
1	$\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$	$\max(\frac{1}{4} \cdot \frac{1}{4} \cdot \frac{1}{4}, \frac{1}{8} \cdot \frac{1}{2} \cdot \frac{1}{4}) = \max(\frac{1}{64}, \frac{1}{64}) = \frac{1}{64}$
2	$\frac{1}{2} \cdot \frac{1}{4} = \frac{1}{8}$	$\max(\frac{1}{4} \cdot \frac{1}{2} \cdot \frac{1}{2}, \frac{1}{8} \cdot \frac{1}{4} \cdot \frac{1}{2}) = \max(\frac{1}{16}, \frac{1}{64}) = \frac{1}{16}$

$$\tilde{P}_M(x) = \max(\frac{1}{64} \cdot \frac{1}{4}, \frac{1}{16} \cdot \frac{1}{4}) = \frac{1}{64}$$

$$\tilde{q}_M(x) = "12F"$$

3. Falso, M genera x con probabilidad $P_M(x)$, siguiendo la secuencia de estados "12F" ($\tilde{q}_M(x)$), "11F", "21F" o "22F". Más precisamente, M genera x mediante "12F" con probabilidad $\tilde{P}_M(x)$; pero también puede generar x mediante una secuencia distinta de "12F", con probabilidad $P_M(x) - \tilde{P}_M(x) = \frac{7}{256} - \frac{1}{64} = \frac{3}{256}$.

4. En la primera iteración, debemos hallar la secuencia de estados más probable con la que M genera "ac", así como la secuencia de estados más probable con la que M genera "cb". La primera, obtenida en el apartado segundo, es "12F". La segunda, dada en el enunciado, es "21F". A partir de los pares ("ac", "12F") y ("cb", "21F"), obtenemos:


$$\pi_1 = \frac{1}{2}, \quad \pi_2 = \frac{1}{2}$$

A	1	2	F
1	0	$\frac{1}{2}$	$\frac{1}{2}$
2	$\frac{1}{2}$	0	$\frac{1}{2}$

B	a	b	c
1	$\frac{1}{2}$	$\frac{1}{2}$	0
2	0	0	$\frac{2}{2}$

En la segunda iteración, partimos de un modelo en el que los símbolos "a" y "b" sólo se emiten en el estado 1, mientras que "c" sólo se emite en el 2. Por tanto, "ac" sólo puede generarse por el camino "12F", y "cb" sólo por "21F". Esto es, obtenemos los mismos pares (cadena-de-entrenamiento, camino-más-probable) que en la primera iteración, por lo que la segunda iteración termina con el mismo modelo que la primera y el algoritmo de re-estimación acaba.

Se tiene un problema de clasificación en dos clases, A y B , de objetos representados mediante cadenas de símbolos en el alfabeto $\Sigma = \{a, b\}$. Las probabilidades a priori de las clases son $P(A) = 0.6$ y $P(B) = 0.4$. La función de probabilidad condicional de la clase A viene caracterizada por un cierto modelo de Markov M_A ; esto es, $P(x | A) = P_{M_A}(x)$. Asimismo, la de la clase B viene dada el modelo de Markov M_B , $P(x | B) = P_{M_B}(x)$:



Sea $x = "aab"$. Se sabe que $P_{M_A}(x) = 0.063872$. Se pide:

1. (1.5 puntos) Calcula $P_{M_B}(x)$ mediante el algoritmo *Forward*.

2. (0.5 puntos) Sea $\tilde{P}_{M_B}(x)$ la aproximación de Viterbi a $P_{M_B}(x)$. Sabemos que, en general, la aproximación de Viterbi no es mayor que la probabilidad exacta, si bien pueden coincidir. En el caso que nos ocupa ($\tilde{P}_{M_B}(x)$ y $P_{M_B}(x)$), y a la vista de la representación gráfica de M_B , sin necesidad de calcular $P_{M_B}(x)$, ¿se puede afirmar que no coinciden, esto es, que $\tilde{P}_{M_B}(x)$ es estrictamente menor que $P_{M_B}(x)$?

3. (0.5 puntos) Halla $P(A | x)$ y $P(B | x)$.

4. (0.5 puntos) Clasifica x por mínima probabilidad de error.

1.

α_{qt}	a	a	b
0	$1 \cdot .9 = .9$	$.9 \cdot .7 \cdot .9 + 0 = .567$	$.567 \cdot .7 \cdot .1 + .054 \cdot 0 \cdot .1 = .03969$
1	$0 \cdot .2 = 0$	$.9 \cdot .3 \cdot .2 + 0 = .054$	$.567 \cdot .3 \cdot .8 + .054 \cdot .5 \cdot .8 = .15768$

$$P_{M_B}(x) = .03969 \cdot 0 + .15768 \cdot .5 = .07884$$

2. En general, la aproximación de Viterbi es estrictamente menor que la probabilidad exacta siempre que haya dos o más caminos que generen la cadena con probabilidad no nula. Esto es así en el caso de x ya que M_B puede generarla con probabilidad no nula por dos caminos: 001F y 011F.

3.

$$P(x) = P(A) P_{M_A}(x) + P(B) P_{M_B}(x) = .6 \cdot .063872 + .4 \cdot .07884 = .0383232 + .031536 = .0698592$$

$$P(A | x) = \frac{P(A) P_{M_A}(x)}{P(x)} = \frac{.0383232}{.0698592} = .5486$$

$$P(B | x) = \frac{P(B) P_{M_B}(x)}{P(x)} = \frac{.031536}{.0698592} = .4514$$

4.

$$c(x) = \arg \max_{c \in \{A, B\}} P(c | x) = A$$